

# DeepSeek як бекенд Claude Code

підміна моделі, ціни на API та GitHub-проекти

Технічний звіт · доповнення    DeepSeek V4 · Claude Code    Дата: 2026-06-05 · Джерела: офіційні доки DeepSeek API + GitHub-репозиторії (звірено вручну)

Цей файл — окреме доповнення до звіту про локальний LLM. Тема: чи можна «підмінити» дорогий хмарний Claude у Claude Code на дешевший DeepSeek, скільки це коштує і якими проектами роблять. Ціни взято з офіційної сторінки DeepSeek [1], метод інтеграції — з офіційної доки [2]. Ціни змінюються — звіряйте перед оплатою.

## 1. Коротка суть (TL;DR)

ТАК, ПІДМІНА ПРАЦЮЄ — І ОФІЦІЙНО

- Claude Code звертається до **Anthropic Messages API**. DeepSeek надає **Anthropic-сумісний ендпоинт** `https://api.deepseek.com/anthropic` — тобто можна перенаправити Claude Code на DeepSeek двома змінними оточення, без жодного проксі [2][3].
- Економія величезна: проекти заявляють **17х–95х дешевше** за підписку Anthropic (~\$7–20/міс проти ~\$200/міс) [5][6], переважно завдяки автоматичному кешуванню контексту в агентних циклах.
- Платите ви за токени DeepSeek** — це не «безкоштовно». «Free» у назвах проектів = безкоштовний софт-проксі, а не безкоштовний inference.
- Приватність:** DeepSeek — хмарний провайдер (Китай). Дані виходять з вашого Mac на їхні сервери — протилежність локальному Ollama. Для конфіденційного коду це суттєво.

## 2. Як працює підміна бекенда

Claude Code дозволяє перевизначити, куди слати запити, через змінні оточення. Оскільки DeepSeek «розмовляє» тим самим протоколом, що й Anthropic, підміна — це просто інша адреса + ключ:

```
export ANTHROPIC_BASE_URL=https://api.deepseek.com/anthropic
export ANTHROPIC_AUTH_TOKEN=<ваш DeepSeek API-ключ>
```

Є три рівні «глибини» підміни:

| Підхід                  | Що робить                                                                        | Проксі?         |
|-------------------------|----------------------------------------------------------------------------------|-----------------|
| Офіційний (env-змінні)  | DeepSeek-ендпоинт напряму; одна модель або мапінг тірів                          | Ні              |
| Локальний проксі-роутер | Перехоплює запити, маршрутизує opus/sonnet/haiku на різні моделі/провайдери      | Так (локальний) |
| MCP-сервер              | Додає DeepSeek як інструмент усередину Claude Code, не підмінюючи основну модель | —               |

### 3. Офіційний метод DeepSeek + Claude Code

За офіційною документацією DeepSeek [2]. Передумови: **Node.js 18+**, встановлений Claude Code ( `npm install -g @anthropic-ai/claude-code` ), ключ з `platform.deepseek.com/api_keys` .

```
# macOS / Linux
export ANTHROPIC_BASE_URL=https://api.deepseek.com/anthropic
export ANTHROPIC_AUTH_TOKEN=<ваш DeepSeek API-ключ>
export ANTHROPIC_MODEL=deepseek-v4-pro
export ANTHROPIC_DEFAULT_OPUS_MODEL=deepseek-v4-pro
export ANTHROPIC_DEFAULT_SONNET_MODEL=deepseek-v4-pro
export ANTHROPIC_DEFAULT_HAIKU_MODEL=deepseek-v4-flash
export CLAUDE_CODE_SUBAGENT_MODEL=deepseek-v4-flash
export CLAUDE_CODE Effort_Level=max

claude
```

#### ЯК МАПЛЯТЬСЯ «ТИПИ» CLAUDE

| Запит Claude Code                                          | → Модель DeepSeek                         |
|------------------------------------------------------------|-------------------------------------------|
| <code>claude-opus-*</code>                                 | <b>deepseek-v4-pro</b> (потужніша)        |
| <code>claude-sonnet-*</code> / <code>claude-haiku-*</code> | <b>deepseek-v4-flash</b> (швидша/дешевша) |

Тобто фонові й легкі задачі йдуть на дешевий Flash, а «важкі» (opus) — на Pro. Можна посадити все на Flash, щоб мінімізувати вартість.

**нюанс Web search у Claude Code генерує додаткові API-запити → додаткові витрати токенів [2]. А деякі сторонні гайди зазначають, що allowlist Claude Code не приймає сирі імена DeepSeek-моделей напряду — тоді запускають з `--model sonnet/opus` і прапорцем `--bare` , щоб обійти OAuth/keychain [6].**

### 4. Ціни DeepSeek API (офіційні)

Станом на дату звіту, з офіційної сторінки [1]. Валюта — **USD за 1M токенів**:

| Модель                                    | Вхід (cache hit) | Вхід (cache miss) | Вихід  | Контекст | Max output |
|-------------------------------------------|------------------|-------------------|--------|----------|------------|
| <b>deepseek-v4-flash</b><br>швидка/дешева | \$0.0028         | \$0.14            | \$0.28 | 1M       | 384K       |
| <b>deepseek-v4-pro</b><br>потужна         | \$0.003625       | \$0.435           | \$0.87 | 1M       | 384K       |

Застарілі (підтримка до 2026-07-24): `deepseek-chat` → v4-flash (non-thinking), `deepseek-reasoner` → v4-flash (thinking). DeepSeek залишає за собою право змінювати ціни — наведене не є офертою.

**ЧОМУ ЦЕ ТАК ДЕШЕВО — КЕШУВАННЯ** Контекстне кешування ввімкнено за замовчуванням. В агентних циклах системний промпт і контекст файлів повторюються, тож після першого запиту вони йдуть як **cache hit** — на Flash це **\$0.0028/М проти \$0.14/М** (≈98% економії). Саме тому реальні сесії коштують копійки.

## 5. Скільки економите проти Anthropic

| Варіант                             | Вхід / Вихід за 1М | Орієнтовно/міс                     |
|-------------------------------------|--------------------|------------------------------------|
| Anthropic Claude (Sonnet-клас, API) | ~\$3 / ~\$15       | підписка ~\$100–200 <sup>[5]</sup> |
| DeepSeek <b>v4-pro</b>              | \$0.435 / \$0.87   | ~\$20 (легке) <sup>[5]</sup>       |
| DeepSeek <b>v4-flash</b>            | \$0.14 / \$0.28    | ~\$7 <sup>[6]</sup>                |

Звідси й заявлені **17х–95х** економії. Точна цифра залежить від частки кеш-хітів і того, чи все на Flash, чи Pro на «важке».

## 6. GitHub-проекти для підміни (зокрема «free-claude-code»)

Це проєкт, який ви згадували — клас «free claude code». Насправді їх кілька; ось ключові:

### free-claude-code (Alishahryar1) <sup>[4]</sup>

Найбагатший за функціоналом проксі: маршрутизує Anthropic API-трафік Claude Code на **17 провайдерів** — NVIDIA NIM, OpenRouter, Google AI Studio (Gemini), **DeepSeek**, Mistral, Kimi, Cerebras, Groq, Fireworks, Z.ai, **LM Studio**, **llama.cpp**, **Ollama** та ін. Підтримує **per-model routing** (Opus/Sonnet/Haiku/fallback на різні провайдери) і нативний `/model` -пікер. Працює і з CLI, і з VS Code / JetBrains, і з чат-ботами. Назв-двійників на GitHub кілька (Andrewkeith83 — через NVIDIA NIM + Telegram-бот; Rishurajgautam24) — звіряйте автора.

### deepclaude (aattaran) <sup>[5]</sup>

Локальний проксі на `localhost:3200` ; зберігає весь UX Claude Code (редагування файлів, bash, git). Бекенди: **DeepSeek V4 Pro (дефолт)**, OpenRouter, Fireworks, Anthropic. Заявлено **17х дешевше** (~\$20/міс проти \$200). Ліцензія MIT. Запуск через `deepclaude.sh` .

#### ОБМЕЖЕННЯ DEEPCLAUDE (ВАЖЛИВО)

- **Vision/зображення через Anthropic-ендпойнт DeepSeek не підтримується**
- **Паралельний виклик інструментів деградує**
- **Немає підтримки MCP-серверних інструментів**
- **Складне міркування інколи краще на Claude Opus**

## claudecode-deepseek-stack (MG-Cafe) <sup>[6]</sup>

Найближче до «чистої підміни двома env-змінними» — **без стороннього проксі**. Ключ кладуть у `~/.config/mg-deepseek/key.env`, налаштування-оверрайд (що нейтралізує дефолти Vertex/Bedrock порожніми рядками) — у JSON, запуск: `claude --bare --settings ...`. Заявлено **~95x дешевше** (~\$7/міс на Flash). Обмеження: треба `--model sonnet/opus` (allowlist не приймає імена DeepSeek), потрібен `--bare`.

### Інші (для повноти)

- **DeepSeek-V4-Claude-Code-MCP** — безкоштовний MCP-сервер, що додає DeepSeek як інструмент у Claude Code/Cursor/Codex (не підмінює основну модель, а доповнює; локально-first, 1M контекст).
- **yksanjo/deepseek-code** — окремий open-source CLI на DeepSeek-V4 («свій Claude Code за 1/100 ціни») — це не підміна, а альтернативний клієнт.
- **raine/claude-code-proxy** — проксі, щоб ганяти Claude Code через підписку ChatGPT/Kimi замість API <sup>[7]</sup>.

## 7. Застереження та ризики

**ПРИВАТНІСТЬ ДАНИХ** DeepSeek — **хмарний** сервіс. Увесь ваш код, контекст файлів і промпти йдуть на сервери DeepSeek (юрисдикція — Китай) і підлягають їхній політиці зберігання. Це **протилежність локальному Ollama**, де нічого не виходить з Mac. Для коду під NDA / персональних даних — серйозний стоп-фактор. Якщо приватність критична — лишайтесь на локальному Ollama (див. основний звіт), а DeepSeek-підміну використовуйте лише для некритичного коду.

- **Функціональні втрати** через Anthropic-ендпойнт DeepSeek: немає vision, деградує паралельний tool use, немає MCP-інструментів <sup>[5]</sup>. Для агентних робочих процесів Claude Code це відчутно.
- **Якість**. DeepSeek V4 сильний у кодингу, але це не паритет з фронтірним Claude на складному міркуванні/довгих агентних ланцюгах.
- **«Free» ≠ безкоштовно**. Безкоштовний лише проксі-софт; за inference DeepSeek платите за токени (хоча й дешево).
- **ToS / стабільність**. Підміна бекенда сторонніми env-змінними не порушує ToS Claude Code сама по собі, але це не офіційно підтримуваний провайдер (на відміну від Bedrock/Vertex), тож гарантій якості/сумісності немає; оновлення Claude Code можуть ламати обхідні прапорці типу `--bare`.
- **Безпека ключів**. Не комітьте `key.env` / API-ключі в git.

## 8. Рекомендація

### ЯК ОБРАТИ

- **Хочете найпростіше й офіційно:** env-метод DeepSeek (розділ 3) — дві основні змінні + мапінг тірів, без проксі.
- **Хочете гнучку маршрутизацію** (різні моделі/провайдери на різні тіри, у т.ч. локальний Ollama як fallback): **free-clause-code** (Alishahryar1) або **deepclaude**.
- **Приватність понад усе:** не DeepSeek, а локальний Ollama з основного звіту. DeepSeek-підміна — для економії на некритичних задачах.
- **Гібрид:** Claude Code на DeepSeek-Flash для рутини + перемикання на справжній Claude для складного. Саме це й дають роутер-проксі.

## Джерела

1. DeepSeek API Docs — Models & Pricing (офіційні ціни) · [api-docs.deepseek.com/quick\\_start/pricing](https://api-docs.deepseek.com/quick_start/pricing)
2. DeepSeek API Docs — Integrate with Claude Code (env-змінні, мапінг) · [api-docs.deepseek.com/quick\\_start/agent\\_integrations/claude\\_code](https://api-docs.deepseek.com/quick_start/agent_integrations/claude_code)
3. DeepSeek API Docs — Anthropic API (сумісний ендпойнт) · [api-docs.deepseek.com/guides/anthropic\\_api](https://api-docs.deepseek.com/guides/anthropic_api)
4. free-clause-code (проксі на 17 провайдерів) · [github.com/Alishahryar1/free-clause-code](https://github.com/Alishahryar1/free-clause-code)
5. deepclaude (агент-луп на DeepSeek V4 Pro, 17× дешевше) · [github.com/aattaran/deepclaude](https://github.com/aattaran/deepclaude)
6. claudecode-deepseek-stack (підміна 2 env, ~95× дешевше) · [github.com/MG-Cafe/claudecode-deepseek-stack](https://github.com/MG-Cafe/claudecode-deepseek-stack)
7. raine/claude-code-proxy (Claude Code через ChatGPT/Kimi) · [github.com/raine/claude-code-proxy](https://github.com/raine/claude-code-proxy)
8. Claude Code — Environment variables (офіц. дока) · [code.claude.com/docs/en/env-vars](https://code.claude.com/docs/en/env-vars)

**Застереження.** Ціни й назви моделей DeepSeek (v4-flash/pro) актуальні станом на дату звіту з офіційної сторінки, але змінюються — звіряйте перед оплатою. Заявлені «17×/95× дешевше» — маркетингові оцінки авторів проєктів за певних патернів використання; ваша економія залежить від частки кеш-хітів і вибору моделі. GitHub-проєкти — сторонні; перевіряйте код і ліцензії перед запуском, особливо ті, що проксують ваші ключі.

**Доповнення до звіту:** «DeepSeek як бекенд Claude Code». Звірено з офіційними доками DeepSeek API та GitHub-репозиторіями (червень 2026). Парна тема — основний звіт «Локальний запуск LLM: Ollama + Open WebUI», розділ 13 (підключення локальної моделі до Claude Code).